Tecnológico de Monterrey

Actividad 5

Evaluación

Análitica de datos y herramientas de inteligencia artificial

19 de octubre de 2026

Rodrigo Zapien Barrios | A01424400

La base tiene 21,632 filas y 14 columnas. Solo tres columnas son cantidades (precio_unitario, total_unidades y total_neto); articulo_id y cp son códigos y se trataron como texto. Las cantidades están muy concentradas en valores pequeños con unos pocos enormes (la mitad de las partidas tiene un total menor a 948 pesos, pero el máximo supera los 2.17 millones). Tras un diagnóstico general (tipos, nulos, ceros, categorías y duplicados) se tomó una decisión por cada problema:

Problemas encontrados y decisión tomada

Hallazgo	Evidencia	Decisión
Nulos en cp	492 registros (2.27%); 285 son de Puebla (no son aleatorios)	No se imputan: es un código, no una cantidad, y el estado ya representa la ubicación. cp no se usa
Estado escrito de varias formas	53 escrituras; 34 al unificar mayúsculas y acentos	"MEXICO" = Estado de México; "Sin Estado" = SIN DATO; quedan 33 categorías
Fecha como texto	Formato dd.mm.aaaa; 0 inválidas	Convertida a fecha
Duplicados exactos	185 filas en 66 folios (103 en la serie A00)	Se conservan y se marcan (menos del 1%; no hay forma de distinguir repetición legítima de error)
Partidas sin costo	1,612 (7.45%), con precio y total en 0 a la vez	Se separan: 20,020 partidas con costo para las regresiones lineales; "sin costo" es la respuesta del punto 6
Total distinto de precio × unidades	94 de 20,020 partidas (0.5%)	Se conservan
Sesgo muy fuerte	Sesgo de 23 en precio y total	Logaritmo; no se eliminan valores
Categorías fragmentadas	77 vendedores, 25 marcas, 53 estados	Agrupar las poco frecuentes en "OTROS"

Partidas sin costo. No son errores: se concentran en ciertas series de folio (XP0 23.8%, XS0 23.2% y XDF 18.9%, contra 4.4% en A00) y marcas (APPLE 96.8%, SCHIC 65.2%, EXOCAD 39.0% y MEDIT 22.2%). Probablemente son obsequios, muestras o bonificaciones, hipótesis que no se confirmó con el socio formador.

Con la regla del rango intercuartílico (IQR) el precio, las unidades y el total tienen miles de valores extremos. No se eliminaron, porque no parecen errores: son equipos o pedidos grandes y justo los más importantes para el negocio. En su lugar se aplicó el logaritmo natural, que comprime los valores grandes.

Variable	Sesgo original	Sesgo con log	Atípicos IQR original	Atípicos IQR con log

precio_unitario	23.63	1.04	1,076	408
total_unidades	9.84	1.61	3,498	1,851
total_neto	23.15	0.75	1,931	320

Agrupación de categorías

Para evitar demasiadas dummies y modelos inestables, se agruparon las categorías con pocas partidas en "OTROS" ("OTRAS" en marcas). Se probaron primero umbrales más bajos (300 para estado y 500 para vendedor), pero dejaban demasiadas categorías sueltas para 1,682 clientes.

Variable	Mínimo de partidas	Categorías	Comentario
Marca	150	11	10 marcas más OTRAS
Estado	700	8	CDMX, Puebla, Edo. de México, Querétaro, Jalisco, Guanajuato, Baja California y OTROS (37% de las partidas)
Vendedor	800	10	9 vendedores más OTROS (42% de las partidas)
Serie de folio	100	9	A00, CP0, B00, XP0, XDF, CDF, S00, TL0 y OTRA_SERIE

Nivel de análisis: cliente

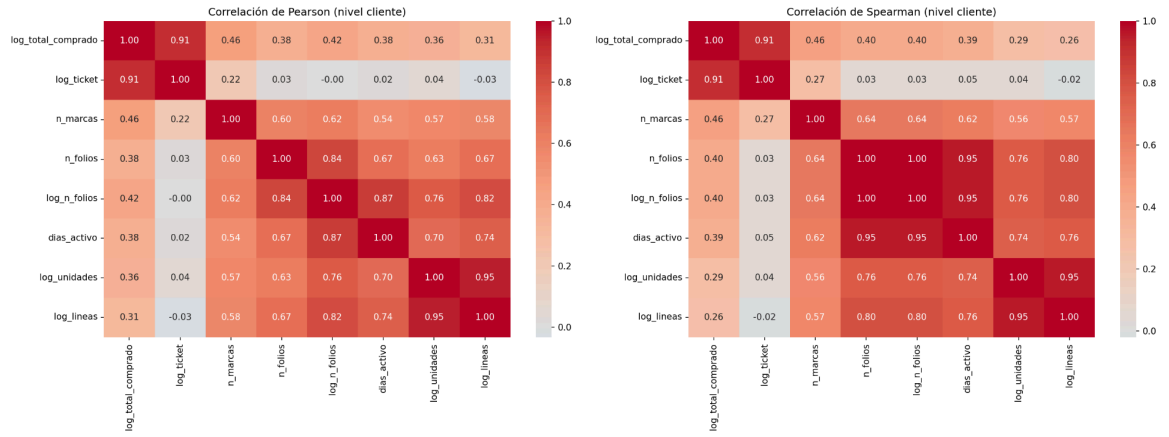
Se evaluaron tres opciones para lo que representa cada fila:

- **Partida:** el total es precio × unidades, así que el R^2 sería casi perfecto sin ningún hallazgo real.
- **Folio:** las variables están ligadas de forma mecánica (líneas y artículos tienen correlación de 1.00) y un mismo cliente aparece en hasta 66 folios, lo que rompe la independencia entre observaciones.
- **Cliente (elegida):** observaciones independientes y variables con sentido de negocio.

La tabla por cliente usa solo partidas con costo: 1,682 clientes (2 se excluyeron por tener solo partidas sin costo). Incluye total comprado, folios, partidas, unidades, marcas y artículos distintos, días activo y estado, vendedor y marca principales. El cliente típico es pequeño (mediana de 7,000 pesos; 53.3% compró en un solo folio) y unos pocos concentran montos enormes, por eso la respuesta de los modelos lineales es log_total_comprado (media 9.14, sesgo 0.32, casi simétrica).

Regresión lineal simple

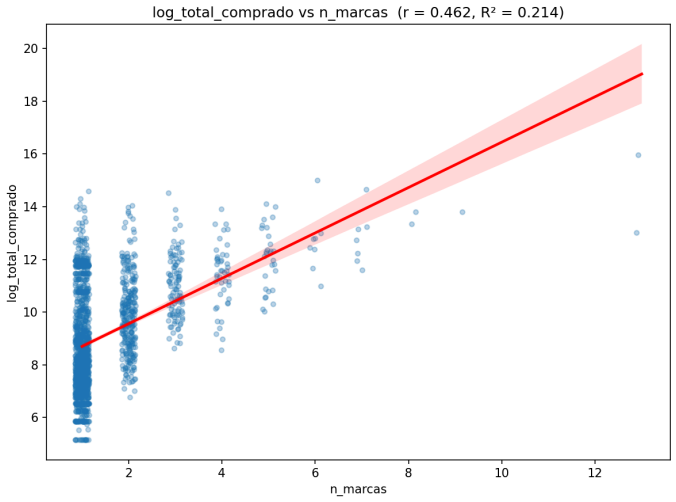
Se calcularon correlaciones de Pearson (relación lineal) y Spearman (por orden, menos sensible a extremos) entre las variables del cliente y log_total_comprado, y se ajustó un modelo simple con la de mayor correlación.



Todas las variables tienen correlación positiva moderada con la respuesta. La más alta, sin contar la algebraica, es el número de marcas (n_marcas: Pearson 0.462, Spearman 0.459), seguida de log_n_folios (0.419), dias_activo (0.385), n_folios (0.377), log_unidades (0.361) y log_lineas (0.315). Pearson y Spearman coinciden en el orden. El modelo simple resultó:

$$\log_total_comprado = 7.8353 + 0.8614 \times n_marcas$$

con r = 0.4625, $\mathbf{R^2 = 0.2139}$, p-valor de la pendiente $\approx 7 \times 10^{-90}$ y n = 1,682.



Interpretación

Como la respuesta está en logaritmo, cada marca adicional multiplica el total por e^0.8614 ≈ 2.4. El modelo estima unos 6,000 pesos para un cliente de una marca, 14,000 para dos y 33,500 para tres. Es estadísticamente significativo, pero explica solo el 21% de la variación, por lo que se pasa al modelo múltiple. Probablemente los clientes de varias marcas tienen necesidades más variadas (por ejemplo, clínicas o laboratorios más grandes), hipótesis que la base no permite confirmar. Solo hubo 1 valor extremo en la respuesta (regla IQR); al quitarlo la pendiente pasó de 0.8614 a 0.8801 y el R^2 de 0.2139 a 0.2101, así que no distorsiona el modelo.

Regresión lineal múltiple

Se buscó el mejor modelo para la misma respuesta y se compararon sus coeficientes con los del simple. En un modelo múltiple cada coeficiente mide el efecto de una variable manteniendo constantes las demás.

Variables candidatas (29): n_marcas, log_n_folios y log_unidades (una por cada grupo de variables repetidas), y dummies de estado (8 categorías), marca (11) y vendedor (10) principales. Una dummy es una columna 1/0 que indica si el cliente pertenece a una categoría; se deja una como referencia (OTROS en estado y vendedor, VITA en marca, la más frecuente).

Selección: (1) revisión del VIF, que mide qué tanto se "encima" una variable con las demás (se quitaría una si fuera mayor a 5; no hubo que quitar ninguna); (2) eliminación hacia atrás: se quitó una a una la variable menos significativa mientras su p-valor fuera mayor a 0.05. Salieron 15 variables (seis estados, siete vendedores y las marcas HUGE e IPD).

El modelo final tiene 14 variables, R^2 = 0.637 (ajustado 0.634), contra 0.21 del simple, y un VIF máximo de 2.95. La Tabla 4 presenta los coeficientes con errores estándar robustos HC3 y los compara con los del modelo simple de cada variable sola.

Modelo múltiple y comparación con el modelo simple

Variable	Coef. simple	Coef. múltiple	IC 95% (múltiple)	p-valor	Efecto en el total (múltiple)
n_marcas	0.861	0.182	0.108 a 0.257	< 0.001	+20% por marca
log_n_folios	0.992	0.228	0.136 a 0.320	< 0.001	Duplicar folios: +17%
log_unidades	0.481	0.475	0.400 a 0.551	< 0.001	Duplicar unidades: +39%
Estado: CDMX	−1.099	−0.350	−0.481 a −0.219	< 0.001	−30% vs OTROS
Marca: MEDIT	2.392	4.032	3.772 a 4.292	< 0.001	× 56 vs VITA
Marca: OTRAS	1.156	2.259	1.891 a 2.628	< 0.001	× 9.6
Marca: AG	1.510	2.238	2.015 a 2.460	< 0.001	× 9.4
Marca: CREATION	0.929	1.380	0.806 a 1.955	< 0.001	× 4.0
Marca: AIDITE	0.284	1.224	1.055 a 1.394	< 0.001	× 3.4
Marca: JENSE	0.253	1.202	0.995 a 1.410	< 0.001	× 3.3
Marca: PHROZ	−1.143	0.802	0.449 a 1.155	< 0.001	× 2.2
Marca: ANAX DENT	−1.499	0.504	0.289 a 0.719	< 0.001	× 1.7
Vendedor: ANGESAL	1.416	0.806	0.182 a 1.429	0.011	× 2.2 vs OTROS
Vendedor: PIETRO	1.534	0.509	0.159 a 0.859	0.004	× 1.7 vs OTROS

Constante del modelo múltiple: 6.6349. Como la respuesta es un logaritmo, un coeficiente b equivale a multiplicar el total por e^b (0.1824 → +20%).

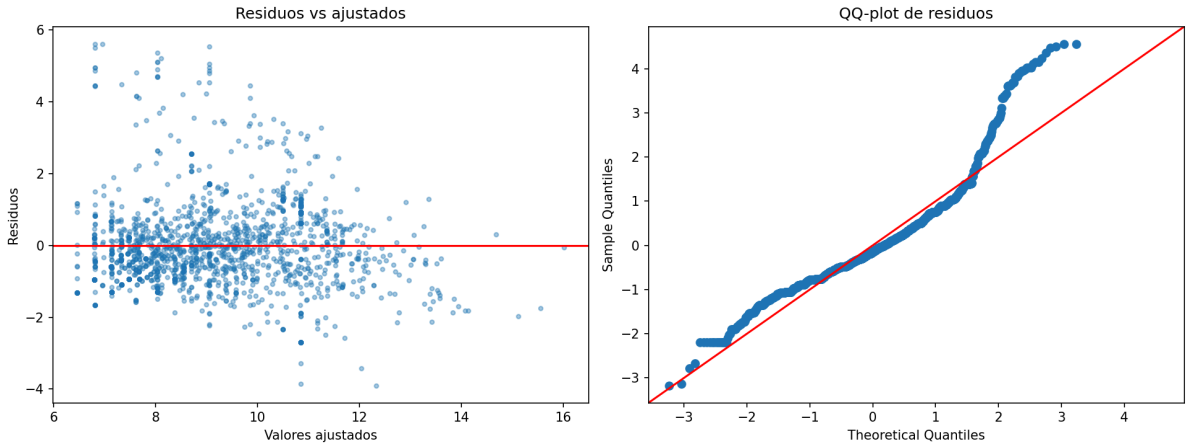
Lectura del modelo

- **Marca principal:** es el factor de mayor peso. Frente a VITA, MEDIT multiplica el total típico por 56 y AG y OTRAS por unos 9. Probablemente son marcas de equipos más caros, pero la base no trae el tipo de producto.
- **Volumen:** las unidades son el predictor numérico más fuerte (beta estandarizado 0.36). También suman folios y marcas.
- **Ubicación y vendedor:** solo Ciudad de México resultó significativo (−30%); solo ANGESAL y PIETRO destacan entre los vendedores, con el efecto más débil del modelo.

Comparación con el modelo simple

- **Los coeficientes numéricos se reducen** al controlar por las demás variables: n_marcas baja 79% (0.861 a 0.182) y log_n_folios 77%. En el simple n_marcas "se llevaba el crédito" de lo que va junto con ella: quien compra más marcas también compra más unidades, más veces y marcas de mayor valor.
- **log_unidades casi no cambia** (0.481 a 0.475): su efecto es propio e independiente.
- **Algunas marcas cambian de signo** (ANAX DENT de −1.50 a +0.50, PHROZ de −1.14 a +0.80) porque el coeficiente simple compara contra todos los demás, y el múltiple contra VITA con las demás variables constantes. Son preguntas distintas.

Diagnóstico y pruebas de robustez



- **Residuos:** sesgo 1.34, curtosis en exceso 3.73, y Jarque-Bera rechaza la normalidad. Hay clientes que gastan mucho más de lo que el modelo espera, y la dispersión de los errores no es constante (heterocedasticidad).
- **Errores robustos HC3:** corrigen la heterocedasticidad sin cambiar los coeficientes. Todas las variables siguen siendo significativas; el cambio mayor fue en ANGESAL (error estándar de 0.183 a 0.318, p = 0.011).
- **Sensibilidad:** sin el único cliente atípico el R^2 pasa de 0.6371 a 0.6347 y los coeficientes casi no cambian. Definir la marca principal por número de partidas (en lugar de gasto, que se relaciona con la respuesta) dio un R^2 ajustado de 0.6415, así que el resultado no depende de esa definición.

El modelo múltiple explica el 63.7% de la variación del total comprado (contra 21%). Importan sobre todo la marca principal y las unidades; folios y marcas aportan menos, y ubicación y vendedor casi nada. Al controlar por las demás, los coeficientes numéricos del simple se reducen 77 a 79% y varias marcas cambian de signo. Las limitaciones son la no normalidad y la heterocedasticidad, atendidas con errores robustos.

Regresión logística con reponderación y oversampling

La regresión logística calcula la probabilidad de un evento de dos valores. Como la base no trae variables dicotómicas, se construyó sin_costo (1 si el total de la partida es cero): 1,612 de 21,632 partidas (7.45%). Se eligió por su sentido de negocio y porque está desbalanceada, justo donde se necesitan reponderación y oversampling.

Variables y problemas resueltos

- Predictoras: log_unidades y dummies de serie de folio, marca, estado y mes (referencia: A00, VITA, OTROS y abril), más una versión con vendedor. No se usaron precio_unitario ni total_neto porque contienen la respuesta (fuga de información).
- Colinealidad entre serie y vendedor: con ambas, el modelo dio razones de momios absurdas ($\approx 10^{11}$) y errores sin valor, porque los vendedores de CDMX y Estado de México trabajan casi solo ciertas series (XDF, CDF y B00) y sus dummies quedan linealmente dependientes. Se comparan dos versiones: A (con serie, sin vendedor; modelo principal) y B (con vendedor, sin serie).
- **Separación perfecta:** cuatro marcas (ANAX DENT, HUGE, IPD y JENSE) y la serie TL0 no tienen ninguna partida sin costo; se agruparon con la referencia.

Cómo se evaluó

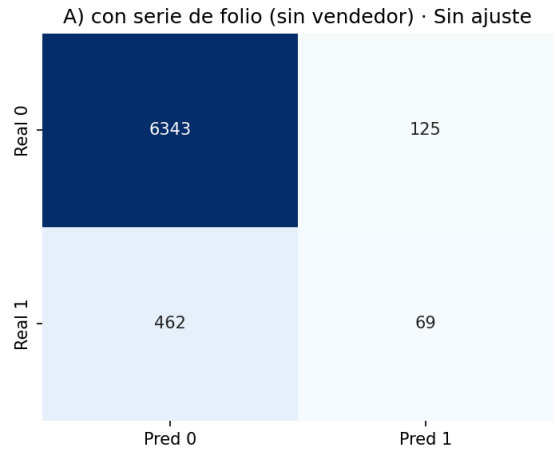
Partición en entrenamiento (2/3: 14,633 partidas, 7.39% sin costo) y prueba (1/3: 6,999, 7.59%), por folio (para que partidas de una misma factura no queden en ambos conjuntos, lo que inflaría los resultados) y estratificada. Escenarios: sin ajuste, reponderación (más peso a los errores sobre la clase rara) y oversampling (duplicar al azar partidas sin costo, solo en entrenamiento).

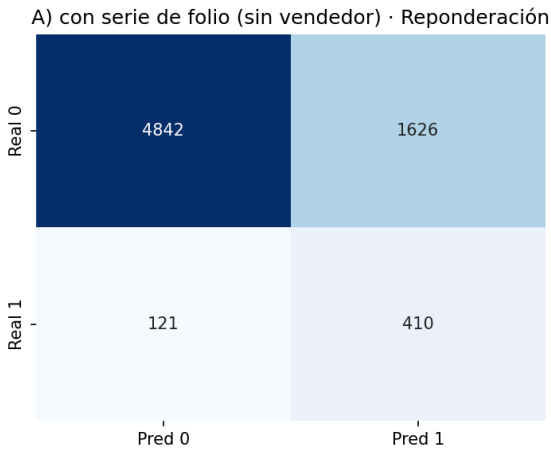
Métricas, con VP, FP, FN y VN (verdaderos/falsos positivos y negativos): exactitud (aciertos totales), precisión (de lo señalado como sin costo, cuánto lo era), sensibilidad (de las sin costo, cuántas se detectaron), especificidad (de las con costo, cuántas se identificaron bien) y AUC (qué tan bien ordena las partidas; 0.5 es azar, 1 perfecto).

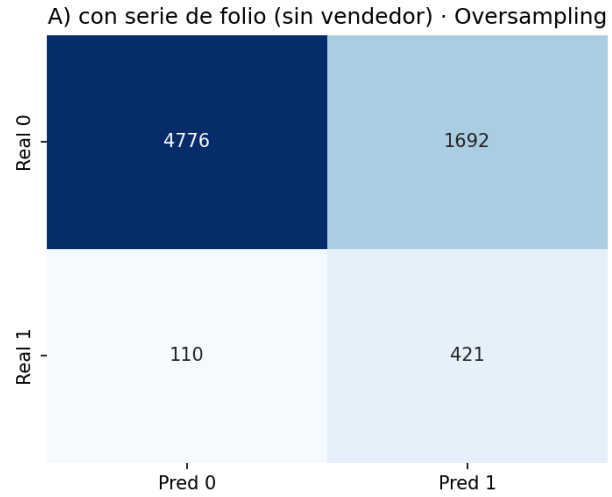
Desempeño en el conjunto de prueba (exactitud de referencia: 0.924)

Versión	Escenario	VP	FP	FN	VN	Exact.	Prec.	Sens.	Espec.	AUC
A (serie)	Sin ajuste	69	125	462	6,343	0.916	0.356	0.130	0.981	0.829
A (serie)	Reponderación	410	1,626	121	4,842	0.750	0.201	0.772	0.749	0.842
A (serie)	Oversampling	421	1,692	110	4,776	0.743	0.199	0.793	0.738	0.839

B (vendedor)	Sin ajuste	4	12	527	6,456	0.923	0.250	0.008	0.998	0.758
B (vendedor)	Reponderación	377	2,188	154	4,280	0.665	0.147	0.710	0.662	0.768
B (vendedor)	Oversampling	378	2,200	153	4,268	0.664	0.147	0.712	0.660	0.764







Interpretación

- **Sin ajuste el modelo no sirve:** su exactitud (0.916) es menor que la de predecir siempre "con costo" (0.924) y detecta solo el 13% de las partidas sin costo (69 de 531); en la versión B, casi ninguna.
- **Con reponderación se detecta el 77%** (410 de 531), con 1,626 falsas alarmas: precisión de 0.20, es decir, una partida señalada es unas 2.6 veces más probable de ser gratuita que una cualquiera (tasa base 7.6%). Reponderación y oversampling dan casi lo mismo (sensibilidad 0.772 y 0.793), así que se prefiere la reponderación por sencilla.
- **El AUC casi no cambia** (0.829, 0.842 y 0.839): reponderar solo mueve el punto de corte, no mejora el orden. Si dejar pasar una partida gratuita es grave, conviene la reponderación; si las falsas alarmas cuestan, un corte más exigente.

- **La serie de folio aporta información:** AUC de 0.84 con serie (A) contra 0.77 con vendedor (B).

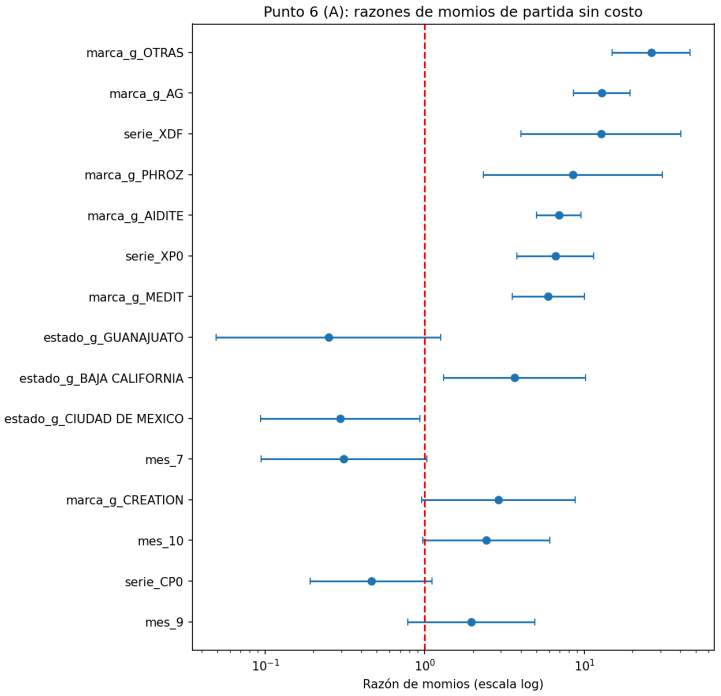
Razones de momios

La razón de momios (OR) indica cuánto se multiplican los momios (probabilidad de que ocurra entre la de que no) del evento: mayor a 1 los aumenta, menor a 1 los disminuye. La Tabla 6 muestra la versión A con errores estándar agrupados por folio (las partidas de un folio no son independientes) y, como comparación, el OR con reponderación.

Razones de momios de que una partida sea sin costo (versión A)

Variable (referencia)	OR	IC 95%	p-valor	OR reponderado
Marca OTRAS (vs VITA)	26.25	14.96 a 46.06	< 0.001	25.55
Marca AG	12.83	8.56 a 19.23	< 0.001	13.60
Serie XDF (vs A00)	12.72	4.01 a 40.32	< 0.001	7.90
Marca PHROZ	8.47	2.34 a 30.74	0.001	16.77
Marca AIDITE	6.91	5.00 a 9.55	< 0.001	7.12
Serie XP0	6.58	3.78 a 11.43	< 0.001	7.55
Marca MEDIT	5.94	3.52 a 10.02	< 0.001	9.85
Estado Baja California (vs OTROS)	3.65	1.31 a 10.21	0.014	3.38
Estado Ciudad de México	0.30	0.09 a 0.93	0.038	0.54
log_unidades	0.68	0.54 a 0.84	< 0.001	0.66

Las demás variables (CREATION, octubre, CP0, julio, otros estados, series y meses) no fueron significativas (p > 0.05).



- **Marca:** frente a VITA, OTRAS (que incluye a APPLE, con 97% de partidas sin costo) tiene unas 26 veces más momios; AG, AIDITE, MEDIT y PHROZ entre 6 y 13 veces.
- **Serie:** XDF (12.7 veces) y XP0 (6.6) frente a A00, coherente con los porcentajes de ceros de la Tabla 1.
- **Unidades:** al duplicarlas, los momios bajan cerca de 24%; las partidas gratuitas tienden a ser de pocas unidades. Ciudad de México tiene menos momios (0.30) y Baja California más (3.65); los meses no muestran patrón.
- El modelo reponderado da ORs del mismo sentido y magnitud parecida, así que las conclusiones no dependen del escenario.

Las partidas sin costo se asocian con ciertas marcas (OTRAS, AG, AIDITE y MEDIT) y series de folio (XDF y XP0) y son de pocas unidades. Sin ajuste no se detecta casi ninguna; con reponderación u oversampling se detecta cerca de tres de cada cuatro, con bastantes falsas alarmas. Sirve para priorizar revisiones, no como regla definitiva, y describe asociaciones, no por qué se entrega un producto sin cargo.

Variables dicotómicas y regresión logística de clientes

Se convirtieron variables a dicotómicas con categorías de sentido de negocio para responder, a nivel cliente: **¿qué distingue a un cliente de alto valor?**

Respuesta: alto_valor = 1 si el total comprado es igual o mayor al percentil 75 (47,413.79 pesos): 426 de 1,682 clientes (25.3%). Se prefirió al percentil 50 porque (1) identifica a los clientes que de verdad pesan en las ventas (con la mediana, quien compró una vez por unos 7,000 pesos sería “de alto valor”), (2) deja una proporción 25/75 que sigue justificando comparar modelo sin ajuste contra reponderado y (3) deja 426 positivos, suficientes para 5 variables. Su desventaja es que el corte sale de los mismos datos.

Variables dicotómicas y su relación con el alto valor

Variable	Definición (1 si…)	Clientes con 1	% alto valor si 1	% alto valor si 0
multimarca	Compró 2 o más marcas	477	42.1%	18.7%
recurrente	Compró en 2 o más folios	785	30.3%	21.0%
volumen_alto	Unidades sobre la mediana	819	26.9%	23.9%
cdmx	Su estado principal es CDMX	425	15.8%	28.6%
marca_alto_valor	Su marca principal es MEDIT o AG	437	55.6%	14.7%

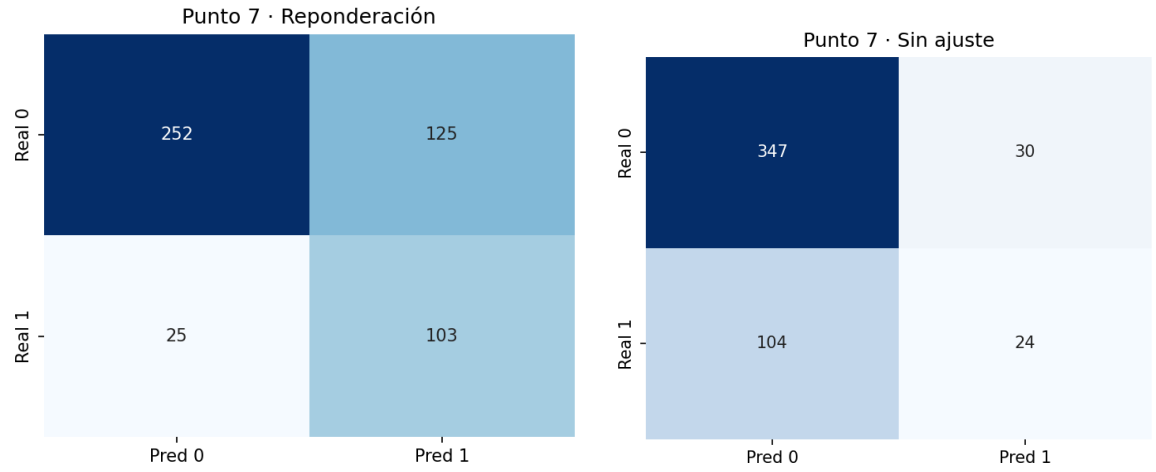
MEDIT y AG se eligieron por ser las marcas de mayor efecto en la regresión lineal múltiple; aquí la marca principal se definió por número de partidas (no por gasto) para no mezclarla con la respuesta. Los VIF fueron todos menores a 2.2 (no hay colinealidad preocupante).

Clasificación

División estratificada en entrenamiento (70%: 1,177 clientes) y prueba (30%: 505), que mantiene el 25.3% de alto valor. Como los clientes sí son independientes, no se requiere dividir por grupos.

Desempeño en el conjunto de prueba (505 clientes; exactitud de referencia: 0.747)

Escenario	VP	FP	FN	VN	Exactitud	Precisión	Sensibilidad	Especificidad	AUC
Sin ajuste	24	30	104	347	0.735	0.444	0.188	0.920	0.783
Reponderación	103	125	25	252	0.703	0.452	0.805	0.668	0.782



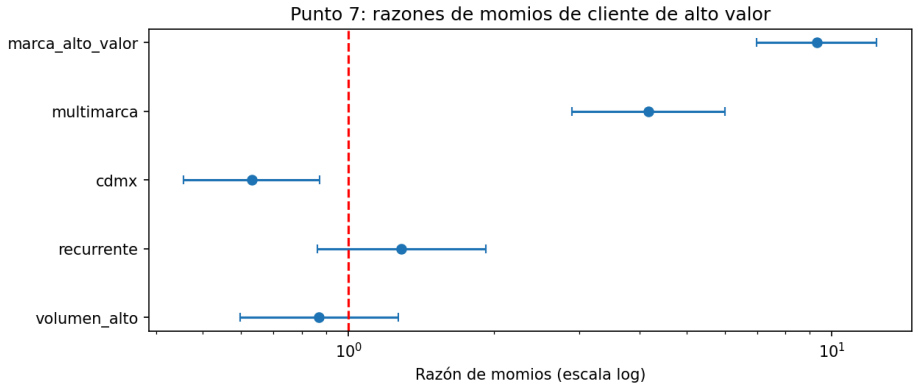
- **Sin ajuste** se detecta solo el 19% (24 de 128); con reponderación, el 80.5% (103 de 128), con 125 falsas alarmas. La precisión de 0.45 es 1.8 veces la tasa base (25.3%).
- La exactitud queda por debajo de la de referencia (0.747, predecir siempre “no alto valor”), por eso se usan sensibilidad y AUC. El AUC es 0.78 en ambos: discriminación aceptable; la reponderación solo mueve el punto de corte.

Razones de momios

Con los 1,682 clientes se ajustó el modelo explicativo (R^2 de McFadden = 0.212, ajuste moderado a bueno; no comparable con el R^2 lineal).

Razones de momios de ser cliente de alto valor

Variable	Coeficiente	OR	IC 95%	p-valor
marca_alto_valor	2.230	9.30	6.99 a 12.38	< 0.001
multimarca	1.430	4.18	2.90 a 6.01	< 0.001
cdmx	−0.461	0.63	0.46 a 0.87	0.005
recurrente	0.253	1.29	0.86 a 1.92	0.216
volumen_alto	−0.140	0.87	0.60 a 1.27	0.467



- Marca principal MEDIT o AG (OR = 9.30): unas 9 veces más momios de ser de alto valor; es el efecto más fuerte.
- Comprar 2 o más marcas (OR = 4.18) y estar en Ciudad de México (OR = 0.63, 37% menos momios).
- Recurrente y volumen alto no resultaron significativos. Ser recurrente parecía importar en la tabla simple (30.3% contra 21.0%), pero al controlar por multimarca su efecto desaparece porque están relacionadas. Volumen alto tampoco, aunque log_unidades era el mejor predictor numérico del modelo lineal: dicotomizar pierde información.

Los resultados concuerdan con el modelo lineal múltiple (marca principal, número de marcas y Ciudad de México con efecto negativo): dos enfoques distintos apuntan a las mismas variables.

Un cliente de alto valor se distingue sobre todo por comprar principalmente MEDIT o AG (OR 9.3) y varias marcas (OR 4.2); los de Ciudad de México tienen menos probabilidad (OR 0.63). Con reponderación se detecta el 80% de los clientes de alto valor (AUC 0.78). El modelo describe qué caracteriza a esos clientes, no demuestra qué los hace comprar más.